



UNIVERSIDAD AUTÓNOMA DEL CARMEN

FACULTAD CIENCIAS DE LA INFORMACIÓN

INGENIERIA EN SISTEMAS COMPUTACIONALES

ALUMNOS:

Francisco Eduardo Reyes Pérez 190268

RAUL EDUARDO COVARRUBAS BALLESTER 220952

TAREA:

PDF CON RESULTADOS DE LA APLICACIÓN ID3 A IRIS

MATERIA:

PROGRAMACION AVANZADA

PROFESOR:

profesor: Jesús Alejandro Flores Hernández

FECHA: 02/09/2026



1. Introduccion

ID3 (Iterative Dichotomiser 3) es un algoritmo de construccion de arboles de decision basado en teoria de la informacion. En cada nodo selecciona el atributo que produce la mayor **ganancia de informacion**, es decir, el atributo que mas reduce la incertidumbre (entropia) respecto a la clase objetivo. El algoritmo solo trabaja con atributos nominales (categoricos) y no realiza poda, por lo que tiende a generar arboles muy detallados y propensos al sobreajuste.

Formulas utilizadas:

Entropia:

$$Entropy(S) = \sum -p(i) \log_2 p(i)$$

Ganancia de informacion:

$$Gain(S, A) = Entropy(S) - \sum ((|S_v| / |S|) * Entropy(S_v))$$

2. Datos y discretizacion utilizados

Se usa unicamente **iris.data.csv** (150 observaciones) como fuente de datos. Debido a que ID3 trabaja con atributos nominales, cada uno de los 4 atributos numericos se discretizo en 3 categorias ("chico", "mediano", "grande") con un criterio simple de ancho igual: se toma el minimo y el maximo de cada atributo y se divide ese rango en 3 partes iguales.

Atributo	Minimo	Maximo	Umbral 1	Umbral 2
sepal	4.3	7.9	5.5	6.7
sepalw	2.0	4.4	2.8	3.6
petal	1.0	6.9	2.967	4.933
petalw	0.1	2.5	0.9	1.7



3. Calculo en el nodo raiz

La clase objetivo tiene 3 valores balanceados (50/50/50), por lo que la entropia inicial es maxima: $\text{Entropia}(S) = \log_2(3) = 1.5850$. La ganancia de informacion de cada atributo se calculo comparando esta entropia contra la entropia ponderada resultante de dividir por cada atributo:

Atributo	Ganancia de informacion Gain(S, A)	Resultado
petalw	1.3187	SE ELIGE (maxima ganancia)
petall	1.2948	No seleccionado
sepall	0.6766	No seleccionado
sepalw	0.3484	No seleccionado

4. Segundo nivel del arbol

La rama **petalw = chico** resulta pura, porque contiene las 50 instancias de *setosa*, por lo que se convierte de inmediato en hoja. Las ramas restantes se siguen dividiendo:

Rama **petalw = mediano** (n = 48, Entropia = 0.3373, distribucion = {'Iris-versicolor': 45, 'Iris-virginica': 3})

Atributo restante	Ganancia
petall	0.2361
sepalw	0.0269
sepall	0.0126

Atributo elegido: **petall**

Rama **petalw = grande** (n = 52, Entropia = 0.4567, distribucion = {'Iris-virginica': 47, 'Iris-versicolor': 5})



Atributo restante	Ganancia
petall	0.1131
sepall	0.0445
sepalw	0.0206

Atributo elegido: **petall**

5. Arbol ID3 completo (sin poda)

El proceso se repite recursivamente hasta llegar a subconjuntos puros o hasta que ya no quedan atributos utiles para separar las clases. El arbol final conserva como nodo raiz a petalw, despues usa principalmente petall y, en algunos subconjuntos, los atributos del sepalo.

En la tabla siguiente se presenta una version resumida de las hojas generadas por el arbol ID3 a partir de los resultados del archivo de Excel:

Condicion	Clase predicha	n	Distribucion
petalw = chico	setosa	50	setosa=50
petalw = mediano / petall = chico	versicolor	1	versicolor=1
petalw = mediano / petall = mediano	versicolor	42	versicolor=42
petalw = mediano / petall = grande / sepall = mediano	virginica	2	virginica=2
petalw = mediano / petall = grande / sepall = grande / sepalw = chico	versicolor	2	versicolor=1, virginica=1
petalw = mediano / petall = grande / sepall = grande / sepalw = mediano	versicolor	1	versicolor=1
petalw = grande / petall = mediano / sepalw = chico	virginica	2	virginica=2
petalw = grande / petall = mediano / sepalw = mediano / sepall = mediano	versicolor	2	versicolor=1, virginica=1
petalw = grande / petall = mediano / sepalw = grande	versicolor	2	versicolor=2
petalw = grande / petall = grande / sepall = mediano / sepalw = chico	virginica	6	versicolor=1, virginica=5



```

petalw = chico: Iris-setosa (50)

petalw = mediano
|-- petall = chico: Iris-versicolor (1)
|-- petall = mediano: Iris-versicolor (42)
|-- petall = grande
|   |-- sepall = mediano: Iris-virginica (2)
|   |-- sepall = grande
|       |-- sepalw = chico: Iris-versicolor (2)
|       |-- sepalw = mediano: Iris-versicolor (1)

petalw = grande
|-- petall = mediano
|   |-- sepalw = chico: Iris-virginica (2)
|   |-- sepalw = mediano
|       |-- sepall = mediano: Iris-versicolor (2)
|       |-- sepall = grande: Iris-versicolor (2)
|-- petall = grande
|   |-- sepall = mediano
|       |-- sepalw = chico: Iris-virginica (6)
|       |-- sepalw = mediano: Iris-virginica (2)
|       |-- sepalw = grande: Iris-virginica (1)
|   |-- sepall = grande
|       |-- sepalw = chico: Iris-virginica (11)
|       |-- sepalw = mediano: Iris-virginica (19)
|       |-- sepalw = grande: Iris-virginica (7)

```

6. Evaluacion del arbol sobre las 150 instancias

Clasificando las mismas 150 instancias con el arbol obtenido (evaluacion sobre el conjunto de entrenamiento): **146 de 150 correctas (exactitud = 97.33%)**.

pred \ real	setosa	virginica	versicolor
setosa	50	0	0
virginica	0	48	2
versicolor	0	2	48

Los errores ocurren entre *versicolor* y *virginica*: 2 casos de *virginica* fueron predichos como *versicolor* y 2 casos de *versicolor* fueron predichos como *virginica*. La especie *setosa* se clasifica correctamente en el 100% de los casos, lo cual coincide con su separacion clara en las medidas de petalo.



7. Conclusiones

La aplicación del algoritmo ID3 al conjunto de datos Iris permitió construir un árbol de decisión capaz de clasificar las especies de flores a partir de sus características principales. Durante el proceso se observó que las variables relacionadas con el pétalo fueron las más importantes para separar las clases, especialmente el ancho del pétalo, ya que obtuvo la mayor ganancia de información y fue seleccionado como nodo raíz. Esto demuestra que no todos los atributos tienen el mismo peso dentro del modelo, pues algunos aportan mayor información para tomar decisiones. Además, los resultados obtenidos muestran que el árbol logró una buena clasificación de las instancias, aunque también se puede notar que, al no aplicar poda, el modelo puede volverse más detallado y depender demasiado de los datos de entrenamiento. Aun así, ID3 resulta útil para comprender de manera clara cómo se toman las decisiones dentro de un sistema de clasificación, ya que representa el conocimiento mediante reglas sencillas y fáciles de interpretar.